



Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ _____ИНФОРМАТИКА И СИСТЕМЫ УПРАВЛЕНИЯ_____

КАФЕДРА _____СИСТЕМЫ ОБРАБОТКИ ИНФОРМАЦИИ И УПРАВЛЕНИЯ_____

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА К НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ

НА ТЕМУ:

Классификация данных LiDAR

Студент ИУ5-64Б
(Группа)
(И.О.Фамилия)

(Подпись, дата) **Б. В. Новиков**

Руководитель

(Подпись, дата) **А.И. Канев**
(И.О.Фамилия)

2024 г.

Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение
высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

УТВЕРЖДАЮ
Заведующий кафедрой ИУ5
(Индекс)
В.И. Терехов
(И.О.Фамилия)
« 07 » февраля 2024 г.

ЗАДАНИЕ
на выполнение научно-исследовательской работы

по теме Кластеризация данных LiDAR

Студент группы ИУ5-64Б

Новиков Богдан Вячеславович
(Фамилия, имя, отчество)

Направленность НИР (учебная, исследовательская, практическая, производственная, др.)
ИССЛЕДОВАТЕЛЬСКАЯ

Источник тематики (кафедра, предприятие, НИР) КАФЕДРА

График выполнения НИР: 25% к нед., 50% к нед., 75% к нед., 100% к нед.

Техническое задание **Исследовать методы кластеризации с помощью машинного обучения для решения задачи сегментации облака точек на отдельные деревья.**

Оформление научно-исследовательской работы:

Расчетно-пояснительная записка на 19 листах формата А4.

Перечень графического (иллюстративного) материала (чертежи, плакаты, слайды и т.п.)

Дата выдачи задания « 07 » февраля 2024 г.

Руководитель НИР

А. И. Канев
(Подпись, дата) (И.О.Фамилия)

Студент

Б.В. Новиков
(Подпись, дата) (И.О.Фамилия)

Примечание: Задание оформляется в двух экземплярах: один выдается студенту, второй хранится на кафедре.

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	4
1 Постановка задачи	5
2 Описание исходных данных и используемых методов	8
3 Выполнение работы	10
ЗАКЛЮЧЕНИЕ	18
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	19

ВВЕДЕНИЕ

LiDAR (от англ. Light Identification Detection and Ranging – обнаружение света и определение дальности) является одной из самых перспективных технологий сканирования с широкой областью применения. Чаще всего она используется для геодезических и картографических задач, позволяя сканировать и воссоздавать различные рельефы и объёмные модели, но также находит применение в качестве сенсоров для автономных транспортных средств, в климатологии и метеорологии, океанологии и ботанике, а также археологии.

Одно из самых широких распространений технология LiDAR получила в лесной отрасли, особенно в области таксации, где она используется для отслеживания изменений структуры лесных массивов и состояний отдельных деревьев. Лазерная таксация позволяет получать максимально точные и объективные данные, при этом затрачивая гораздо меньше ресурсов и не требуя слишком дорогостоящего оборудования. Сбор данных может производиться как с воздуха, так и с земли. Получившееся в результате сканирования местности облако точек необходимо классифицировать и сегментировать, после чего можно исследовать отдельно взятые деревья, замерять их параметры, прослеживать состояние и др.

Целью данной научно-исследовательской работы является исследование методов кластеризации на основе технологий машинного обучения для сегментации облака точек на отдельные деревья. Задачами данной работы являются исследование существующих методов машинного обучения для кластеризации и основанная на них сегментация деревьев из облака точек с последующей оценкой качества этих методов.

1 Постановка задачи

В результате наземной съёмки деревьев сканнером LiDAR было получено трёхмерное облако точек. Задача состоит в сегментации получившегося набора точек на отдельные деревья, то есть в выделении классов для каждого индивидуального дерева и присвоения каждой точке подходящего ей класса. Сложность сегментации заключается в том, что деревья расположены близко друг к другу, из-за чего их кроны переплетаются, и становится проблематично определить, к какому именно дереву стоит отнести точки.

Актуальность решаемой задачи растёт вместе с расширением области применения технологии LiDAR и активной разработкой новых методов обработки результатов сканирования. В отрасли лесного хозяйства задача сегментации деревьев играет огромную роль и позволяет решать множество разнообразных задач: от слежения за состоянием отдельно взятых деревьев до сканирования целого лесного массива для сбора информации о рельефе.

Леса являются ценным природным ресурсом, который поддерживает экосистему на благо человечества, в том числе сохранение биоразнообразия, участие в круговороте углерода и уменьшение парникового эффекта. Однако различные болезни, вредители и экстремальные погодные условия могут вызвать гниение деревьев, засуху и прочие заражения. Поэтому поддержание и мониторинг состояния лесов имеет огромное значение для сохранения целостности лесных экосистем. Традиционные методы лесопользования, такие как полевая съёмка, требуют очень много времени и затрат из-за большой площади лесов. С развитием технологий дистанционного зондирования состояние лесов можно оценивать без проведения измерений на месте экономически эффективным способом с высоким качеством (Wong и др. [1]).

С точки зрения лесного хозяйства, способность быстро и надёжно обнаруживать деревья в различных ситуациях остается важной задачей для разработки множества приложений. Например, на выбор дерева при прореживании заметно влияют переменные параметры дерева, такие как

плотность стволов и крон, высота, диаметр и виды, что делает внешний вид дерева чрезвычайно разнообразным. На данный момент визуальные возможности человека-оператора являются единственными, способными оценить эти параметры и принять обоснованное решение во время лесохозяйственных работ. Однако будущая автоматизация этих работ с помощью методов машинного обучения и компьютерного зрения сможет снизить нагрузку на человека (Grondin и др. [2]).

Понимание роста деревьев является важным фактором для владельцев коммерческих садов (Westling, Underwood, Bryson [3]). Коммерческие лесоводы полагаются на регулярные инвентаризации своего леса с точки зрения количества деревьев на данной территории, их высоты и других размеров, часто на больших площадях. Благодаря точному знанию местоположения деревьев, их индивидуальной структуры, а также количества и качества содержащейся в них древесины можно более эффективно использовать ресурсы во время лесозаготовительных работ и более оптимально планировать решения в цепочке поставок (Windrim, Bryson [4]).

Автоматическая идентификация и картографирование деревьев является давней целью в области дистанционного зондирования лесов, и в настоящее время существует особый интерес к поиску надежных решений для сегментации многовидовых насаждений со сложной структурой. Благодаря широкому внедрению систем LiDAR стало возможным собирать данные о трехмерной структуре лесных насаждений на площади в сотни квадратных километров за считанные часы, обычно в виде 3D-облаков точек, из которых можно сегментировать отдельные деревья (Williams и др. [5]).

Задачу сегментации трёхмерного облака точек можно решать очень многими способами. Одним из часто встречающихся является метод, основанный на графах, так как он позволяет быстро обрабатывать большие объёмы данных, а также менее чувствителен к шумам и выбросам, возникающим из-за данных низкого качества. Например, в работе [3] был разработан метод, который сначала объединяет точки в воксели, которые и являются вершинами

графов, затем соседние воксели соединяются рёбрами и строятся пути. После суммирования путей можно оценить, сколько аз каждая вершина попала в путях, что пропорционально её участию в сети дерева и кратчайшему пути к ней. Далее с полученными результатами можно проводить различные сегментации. Эти методы определения местоположения и сегментации показали хорошие результаты, получив F1 score 0,774 и v-measure 0,915, в то время как классификация ствола показала плохие результаты с F1 score 0,490 на реальных данных, хотя продемонстрировала значительно малое время выполнения.

Другие методы используют относительную однородность формы деревьев в лесной среде для сегментации. В статье [4] описан метод, основанный на геометрии деревьев. На 2D изображении с видом сверху используется детектор объектов Faster-RCNN используется для определения границ деревьев путем вывода ограничивающих рамок в плоскости, которые проецируются в трехмерные кубоиды, и все 3D-точки внутри идентифицируются как принадлежащие отдельному дереву. Оценка метода с помощью метрик выдала следующие результаты в среднем: Precision 1.0, Recall 0,946 и F1 score 0,971, показав результаты в 2 раза лучше, чем метод кластеризации DBSCAN.

Также множество методов основываются на нейросетях и глубоком обучении. В работе [6] предлагается библиотека глубокого обучения на основе многоканальной взаимодополняемости информации для обнаружения и сегментации деревьев. На первом этапе определяются точки заземления. Для обнаружения дерева сначала разработан модуль topdown slice (TDS), позволяющий извлекать информацию о вертикальной структуре нисходящим способом. Затем разрабатывается специальное многоканальное представление, которое позже с помощью специальной сети MBNet объединяется для обнаружения и сегментации. Данный метод обеспечивает многообещающую производительность при среднем recall 89,23% и средним F1 score 87,04%.

2 Описание исходных данных и используемых методов

Исходными данными является трёхмерное облако точек, полученное в результате съёмки датчиком LiDAR. Эти данные представляют из себя массив координат по трём осям для 10000 точек. При отрисовке этого облака видно, что оно представляет из себя очертания четырёх близстоящих деревьев разнообразной формы (Рисунок 2.1). Задача заключается в том, чтобы разделить этот массив точек на 4 отдельных дерева и соответствующим образом их раскрасить в качестве визуализации.




Рисунок 2.1 – Исходное облако точек

В качестве метода для кластеризации был выбран DBSCAN (Density-Based Spatial Clustering of Applications with Noise) – плотностный алгоритм пространственной кластеризации с присутствием шумов. DBSCAN выполняет итерацию по случайным точкам из набора данных, для каждой вычисляя окрестности её. Если эта окрестность содержит более определенного заданного количества точек, то эта точка включается в область. Каждая соседняя точка проходит через один и тот же процесс до тех пор, пока она больше не сможет расширять кластер. Если у рассматриваемой точки недостаточно соседей, она будет помечена как шум, что позволяет алгоритму быть устойчивым к выбросам. На вход алгоритма подается два обязательных параметра: минимальное число соседей точки для её включения в кластер и эпсилон (ϵ) – максимальное расстояние между двумя точками, то есть радиус поиска соседей вокруг точки.

Аналогичным методом является OPTICS (Ordering Points To Identify the Clustering Structure), который лучше работает на больших объёмах данных. Он динамически подбирает параметр радиуса эpsilon, что позволяет исключить этот параметр из подбора при применении алгоритма. Попытка применения данного алгоритма показала плохие результаты на исходном наборе данных, поэтому в работе он не используется.

Для оценки качества кластеризации будут использоваться две метрики. Silhouette score (оценка силуэта), рассчитываемая по формуле (1), показывает, насколько объект похож на свой кластер по сравнению с другими кластерами. Метрика принимает значение от -1 до 1, где значение близкое к 1 означает хорошую кластеризацию, 0 показывает перекрывающиеся кластеры, а -1 неправильную кластеризацию.

$$Sil(c) = \frac{1}{N} \sum_{c_k \in C} \sum_{x_i \in c_k} \frac{b(x_i, c_k) - a(x_i, c_k)}{\{a(x_i, c_k), b(x_i, c_k)\}}, \#(1)$$

где $a(x_i, c_k)$ – среднее расстояние от каждой точки x_i до других объектов кластера c_k (компактность);

$b(x_i, c_k)$ – среднее расстояние от каждой точки x_i до объектов из других кластеров кластера c_k (отделимость).

В качестве второй метрики будет использоваться ассурасу (аккуратность), выражающаяся как количество правильно определённых кластеров к их общему количеству. Однако автоматизировать данную метрику не получится, так как программа может определить только количество выделенных кластеров, но не их правильность, поэтому эта метрика будет оцениваться визуально.

3 Выполнение работы

3.1 Разработка алгоритма сегментации на основе метода DBSCAN.

Работа начинается с выполнения примера по заранее заготовленным функциям сегментации на основе метода DBSCAN, функции визуализации с присвоением цветов каждому кластеру и выставленными параметрами $\text{eps} = 0.5$ и $\text{min_samples} = 240$ (Рисунок 3.1). Значение метрики silhouette score составило 0.377. Как видно, было распознано 4 кластера, но неверно, так как у одного дерева отделилась крона. Это означает, что заданные параметры не подходят для исходных данных.



Рисунок 3.1 – Результат сегментации при $\text{eps} = 0,5$ и $\text{min_samples} = 240$

Eps и min_samples являются гиперпараметрами, то есть не существует алгоритмов для их точного определения, однако их можно оптимизировать в рамках конкретной задачи. Было принято решение начать полный перебор гиперпараметров eps и min_samples , а после выделение всех результатов, при которых число выделенных кластеров равнялось 3. И он дал результаты.

Перебор значений шел для eps от 0.3 и до 0.6 с шагом 0.1 и для min_samples от 50 до 300 с шагом 20. В результате перебора была получена таблица, часть которой представлена ниже (Таблица 3.3). При значениях $\text{eps} < 0.3$ получается сегментировать только стволы, а вся крона определяется в класс шумов (Рисунок 3.4). При значениях $\text{min_samples} < 100$ получаются чересчур обобщённые кластеры (Рисунок 3.5). Самыми оптимальными получаются значения в

диапазоне от 200 до 250, ведь они правильно сегментируют бóльшую часть крон.
(Рисунок 3.6).

eps	min_samples
0.4	50
0.4	70
0.4	130
0.4	150
0.4	170
0.4	190
0.4	210
0.4	230
0.4	250
0.4	270
0.4	290
0.5	50
0.5	70
0.5	250
0.5	270
0.5	290
0.5	200
0.5	210
0.5	220
0.5	230
0.5	250

Таблица 3.3 – Часть таблицы из подбора значений min_samples и eps



Рисунок 3.4 – Результат сегментации при eps = 0,1 и min_samples = 50




Рисунок 3.5 – Результат сегментации при $\text{eps} = 0,3$ и $\text{min_samples} = 50$



Рисунок 3.6 – Результат сегментации при $\text{eps} = 0,52$ и $\text{min_samples} = 220$

Полученный алгоритм не является идеальным и нуждается в доработке. Поскольку он работает вслепую, иногда результаты могут получиться довольно посредственными. Для данного алгоритма также требуется подбирать параметры. Однако достоинством разработанного алгоритма, несомненно, является возможность избавления от класса шумов без удаления точек из массива, что позволяет сохранять форму облака.

3.2 Применение алгоритма сегментации.

Выполнение работы начинается со знакомства с инструментом для обработки трехмерных облаков точек CloudCompare. Первым делом импортировал .laz файл с облаком точек:

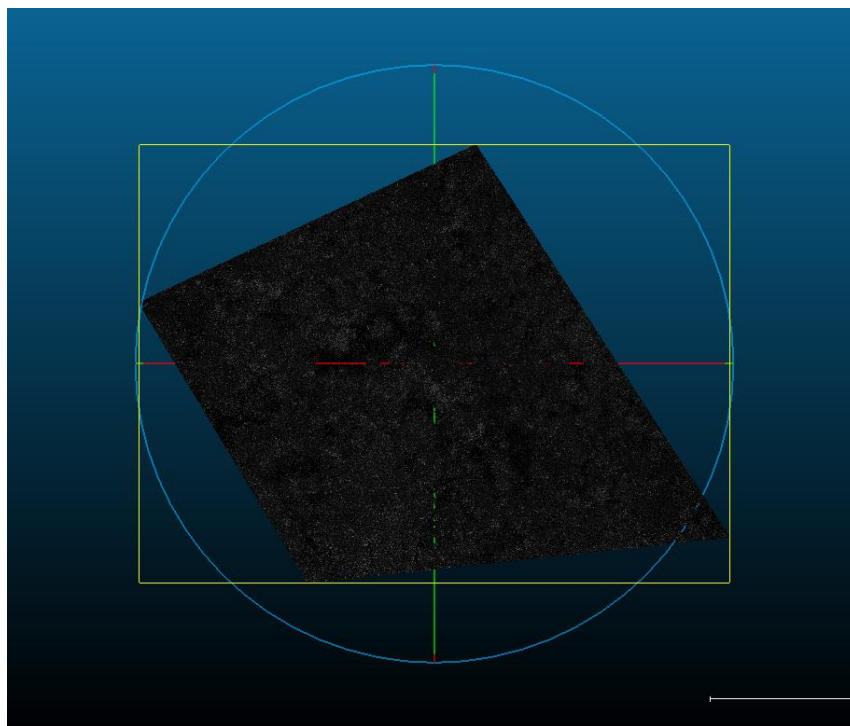


Рисунок 4.1. Исходное облако точек

С помощью инструмента «Cross Section» вырезал свою область согласно рисунку (красная):




Рисунок 4.2. Разделение области

Далее в файле с координатами деревьев отсортировал их по возрастанию по полю X_Local, выбрал первые 417 точек и импортировал в проект:

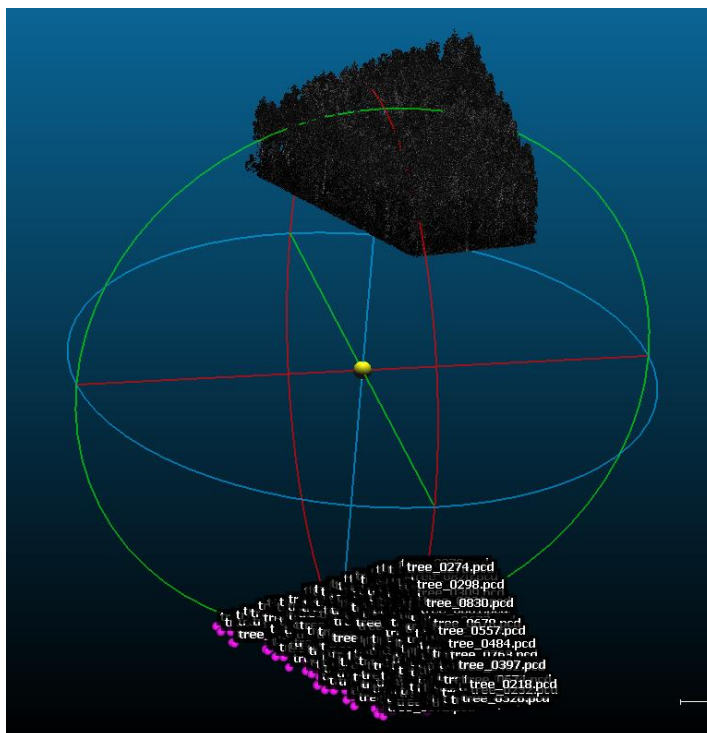


Рисунок 4.3. Исходное положение координат деревьев

Координаты деревьев оказались смещены относительно облака точек по оси Z. С помощью инструмента «Translate/Rotate» сместил плоскость с координатами деревьев под облако точек:




Рисунок 4.4. Готовая рабочая область

Далее с помощью инструмента «Cross Section» я выделял из общего облака точек слева направо небольшие участки и экспортировал в отдельные файлы проекта для дальнейшей сегментации.

Для сегментирования дерева из облака точек использовал встроенный плагин «treeiso» [6]. Он основан на концепции, согласно которой деревья представляют собой пространственную геометрию с большими горизонтальными промежутками между соседними стеблями, но значительно меньшими трехмерными промежутками внутри единицы дерева. В основе лежит двухэтапная Cut-Pursuit кластеризация, сосредоточенная на чистой связности графа.

Экспортировав нужный участок точек в отдельный файл, применяю плагин, работа которого состоит из трех этапов: Initial segmentation, Interim segmentation и Refined segmentation. Для каждого из этапов необходимо указать подходящие значения гиперпараметров: K – максимальное количество соседей, λ – степень регуляризации, m – точность вычислений.

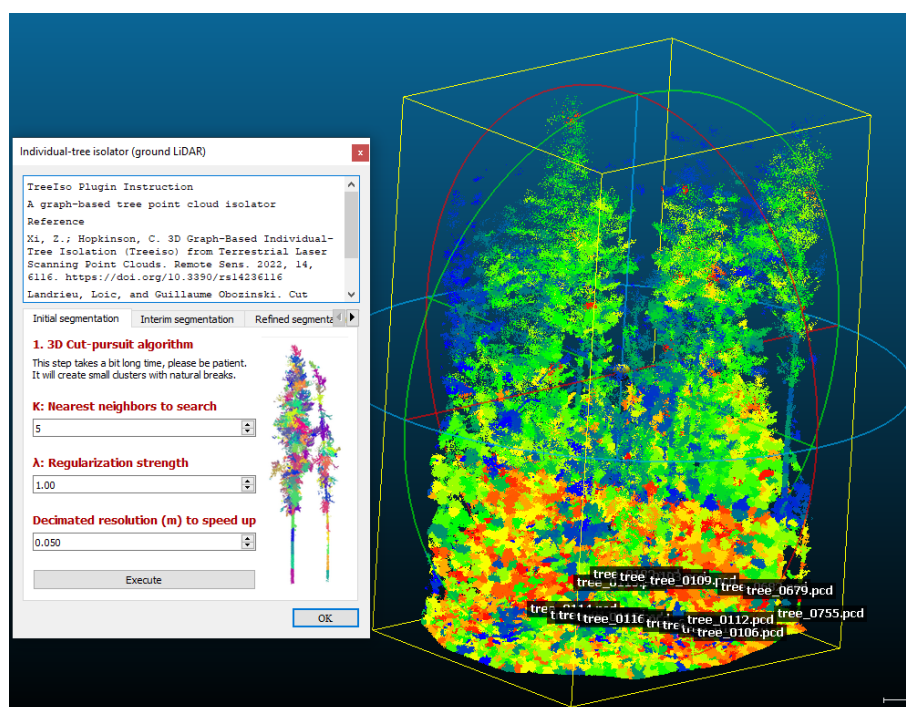


Рисунок 4.5. Результат первого этапа сегментации

Получающиеся в результате первого этапа небольшие кластеры образуют значимые участки ветвей и крон для дальнейшей кластеризации на уровне отдельного дерева.

Выбор гиперпараметров зависит от степени близости и связности отдельных деревьев относительно друг друга. Например, в следующем примере были выбраны следующие параметры для достижения максимальной точности сегментации: $K = 8$, $\lambda = 2$, $\text{max_gap} = 2$, $m = 0.05$.

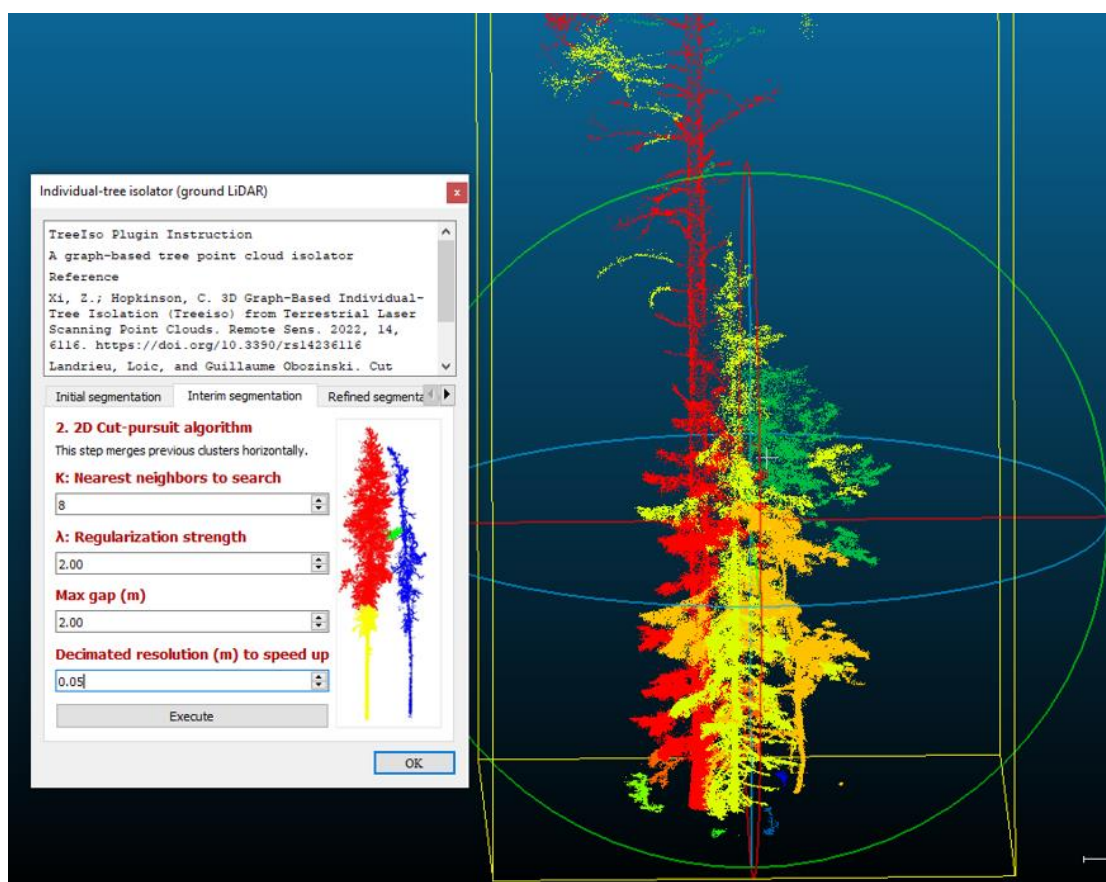


Рисунок 4.6. Второй этап сегментации

В случаях, когда деревья не находятся на очень близком расстоянии можно обойтись $m = 0.2$ для увеличения скорости выполнения алгоритма.

Третий этап необходим для завершения работы плагина, объединения оставшихся сегментов.

Во многих случаях после обработки плагина также необходима ручная очистка облака от лишних точек и слияние недосегментированных деревьев. Полученное облако точек делим на сегменты с помощью команды «Scalar Fields/Split cloud» и осуществляем удаление ненужных. Деревья, у которых отделились части, выделяем и объединяем с помощью команды «Edit/Merge».




Рисунок 4.7. Применение для сегмента «Color Scale»

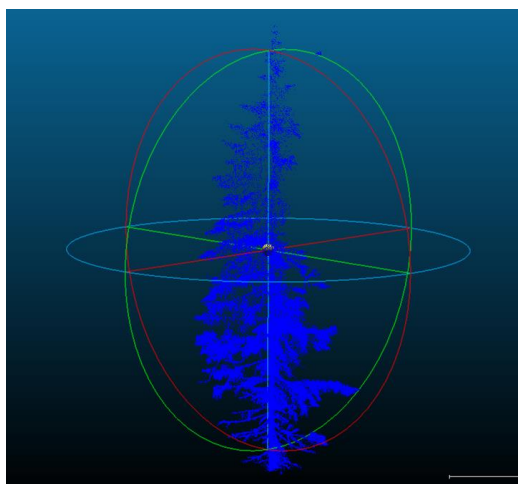


Рисунок 4.8. Пример конечного результата

Указанный алгоритм необходимо применять итеративно до тех пор, пока не удастся выделить нужное дерево из облака точек и при этом не захватить лишние точки.

ЗАКЛЮЧЕНИЕ

В результате выполнения данной научно-исследовательской работы были выполнены следующие задачи:

1. Были изучены методы кластеризации DBSCAN и OPTICS, а также методы подбора оптимальных гиперпараметров для их работы. Вдобавок были использованы метрики Silhouette score и Accuracy для оценки их работы.
2. Был разработан алгоритм, дополняющий работу метода DBSCAN, позволяющий указывать число максимальных кластеров и включать обработку класса шумов, для успешной сегментации облака точек на отдельные деревья.
3. Изучены методы сегментации деревьев из облака точек в CloudCompare.
4. Были протестированы и сравнены несколько методик сегментации, выбраны оптимальные параметры для получения наилучших результатов.

Таким образом, сегментация деревьев из облака точек с использованием LiDAR данных позволяет эффективно выявлять индивидуальные деревья в лесных массивах. Исследуемые методы сегментации могут быть успешно применены в различных областях, связанных с анализом и управлением лесными ресурсами. Дальнейшие исследования могут быть направлены на автоматизацию процесса сегментации и поиск более оптимальных параметров для повышения точности и эффективности анализа.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Vincent Grondin, Jean-Michel Fortin, Francois Pomerleau, Philippe Giguere. Tree Detection and Diameter Estimation Based on Deep Learning: [Электронный ресурс]. // arXiv.org. 2023. Дата обновления: 31.10.2022. URL: <https://arxiv.org/abs/2210.17424> (Дата обращения: 26.03.2024).
2. Fred Westling, James Underwood, Mitch Bryson. Graph-based methods for analyzing orchard tree structure using noisy point cloud data: [Электронный ресурс]. // arXiv.org. 2023. Дата обновления: 02.02.2021. URL: <https://arxiv.org/abs/2009.13727> (Дата обращения: 26.03.2024).
3. Lloyd Windrim, Mitch Bryson. Forest Tree Detection and Segmentation using High Resolution Airborne LiDAR: [Электронный ресурс]. // arXiv.org. 2023. Дата обновления: 30.10.2018. URL: <https://arxiv.org/abs/1810.12536> (Дата обращения: 26.03.2024).
4. Jonathan Williamsa, Carola-Bibiane Schonlieb, Tom Swinfield, Juheon Lee, Xiaohao Cai, Lan Qie, David A. Coomes. Three-dimensional Segmentation of Trees Through a Flexible Multi-Class Graph Cut Algorithm (MCGC): [Электронный ресурс]. // arXiv.org. 2023. Дата обновления: 20.03.2019. URL: <https://arxiv.org/abs/1903.08481> (Дата обращения: 26.03.2024).
5. Zhipeng Luo, Ziyue Zhang, Wen Li, Yiping Chen, Cheng Wang, Abdul Nurunnabib, Jonathan Li. Detection of individual trees in UAV LiDAR point clouds using a deep learning framework based on multi-channel representation: [Электронный ресурс]. // uwaterloo.ca. 2023. Дата обновления: 27.11.2021. URL: https://uwaterloo.ca/geospatial-intelligence/sites/default/files/uploads/files/2021_luo_zhang_li_chen_wang_nurunna_bib_li_tgrs.pdf (Дата обращения: 28.03.2024).
6. Xi, Z.; Hopkinson, C. 3D Graph-Based Individual-Tree Isolation (Treeiso) from Terrestrial Laser Scanning Point Clouds. Remote Sens. 2022, 14, 6116.: [Электронный ресурс]. // doi.org. 2023. Дата обновления: 04.01.2023. URL: <https://doi.org/10.3390/rs14236116> (Дата обращения: 26.03.2024).